Engineering Science and Technology, an International Journal 47 (2023) 101525

Contents lists available at ScienceDirect

Engineering Science and Technology, an International Journal

journal homepage: www.elsevier.com/locate/jestch

Mật độ đỉnh cao có khả năng mờ dựa trên di truyền *c*-có nghĩa là các thuật toán để phân tích cụm- một nghiên cứu điển hình về phân khúc khách hàng

R. J. Kuo [a], Muhammad Naufal Alfareza [a], Thi Phương Quyên Nguyễn [b,*]

a *Khoa Quản lý Công nghiệp, Đại học Khoa học và Công nghệ Quốc gia Đài Loan, Số 43, Đoạn 4, Đường Kee-Lung, Đài Bắc 106, Đài Loan* b *Khoa Quản lý Dự án, Đại học Khoa học và Công nghệ Đà Nẵng, 54 Nguyễn Lương Bằng, Đà Nẵng, Việt Nam*

ARTICLEINFO

Từ khóa: Phân khúc khách hàng Phân cụm đỉnh mật độ Thuật toán di truyền Thuật toán c-mean mờ khả năng

ABSTRACT

Việc tìm kiếm người tiêu dùng mục tiêu cho một doanh nghiệp phụ thuộc rất nhiều vào cách tiếp cận phân khúc thị trường của doanh nghiệp. Áp dụng phân tích phân cụm để phân khúc người tiêu dùng là một trong những phương pháp phổ biến nhất. Tuy nhiên, hầu hết các thuật toán phân cụm có thể dễ dàng rơi vào nghiệm tối ưu cục bộ. Ngoài ra, việc xử lý nhiễu và các giá trị ngoại lệ cũng như xác định các tham số tối ưu có thể là một thách thức. Các trung tâm cụm ban đầu cũng có thể ảnh hưởng đến kết quả phân cụm. Do đó, nghiên cứu này đề xuất một thuật toán phân cụm trước tiên sử dụng phân cụm đỉnh mật độ để thu được các tâm cụm ban đầu. Sau đó, phương pháp đề xuất tích hợp thuật toán di truyền (GA) với thuật toán c-means mờ khả năng (PFCM), trong đó GA được sử dụng để tối ưu hóa tâm cụm và các tham số của thuật toán PFCM nhằm khắc phục các vấn đề trên. Sử dụng 11 bộ dữ liệu chuẩn, kết quả tính toán chứng minh rằng thuật toán được đề xuất có thể mang lại kết quả tốt hơn và chắc chắn hơn về độ chính xác, chỉ số Rand được điều chỉnh (ARI) và thông tin lẫn nhau được chuẩn hóa (NMI) so với các thuật toán phân cụm trước đó. Ngoài ra, thuật toán đề xuất được sử dụng để phân khúc khách hàng của một công ty bán lẻ trong tập dữ liệu chứa các biến số lần truy cập gần đây, tần suất và tiền tệ (RFM). Kết quả phân cụm để phân khúc khách hàng cũng rất hứa hẹn.

1. Giới thiệu

Để đáp ứng nhu cầu đa dạng của khách hàng, việc phân khúc thị trường đã trở thành một vấn đề quan trọng mà các công ty cần quan tâm. Nó có thể giúp một công ty nhận ra nhiều hơn về sở thích của khách hàng và thực hiện các chiến lược tiếp thị khác nhau cho các phân khúc mục tiêu nhằm cải thiện sự hài lòng của khách hàng và tăng doanh thu của công ty [1]. Tuy nhiên, việc phân khúc kém do lựa chọn sai phương pháp có thể không xác định được các nhóm đáng theo đuổi hoặc giữ lại và có khả năng dẫn đến lãng phí nguồn lực rất lớn do công ty điều chỉnh thị trường của mình [2].

Một trong những kỹ thuật phổ biến nhất để phân khúc thị trường là sử dụng phân tích phân cụm. Phương pháp phân cụm là một cách hiệu quả để thực hiện phân khúc thị trường vì nó có thể phân nhóm các cụm một cách rõ ràng [3]. Nhiều thuật toán phân cụm đã được đề xuất với những ưu điểm và nhược điểm tương ứng. Nhiệm vụ thách thức nhất trong thuật toán phân cụm là độ nhạy đối với các trung tâm cụm ban đầu vì chúng có tác động lớn đến kết quả phân cụm [4]. Ngoài ra, còn có các vấn đề khác đối với phân tích phân cụm, chẳng hạn như khả năng xử lý dữ liệu chứa các giá trị ngoại lệ và nhiễu cũng như giải pháp tối ưu cục bộ [5]. Tuy nhiên, không có một kỹ thuật phân cụm đơn lẻ nào có khả năng giải quyết tất cả các vấn đề nêu trên và mang lại kết quả tốt cho mọi loại dữ liệu khác nhau.

Một số phương pháp phân cụm đã được công bố, trong đó phương pháp phân cụm dựa trên mật độ mang lại nhiều ưu điểm hơn các phương pháp khác về khả năng xử lý tiếng ồn. Vương và cộng sự. [6] đã đề xuất một biến thể của phân cụm đỉnh mật độ (DPC) thực hiện nhiệm vụ phân cụm theo phân bố nhiều mật độ. Li và cộng sự. [7] đã kết hợp DPC với mô hình ngữ nghĩa mờ để cung cấp thước đo mật độ cục bộ mới cũng như khoảng cách ngữ nghĩa để lựa chọn trung tâm cụm tốt hơn. Lưu và cộng sự. đã phát triển thuật toán mờ *c*-means (DP-FCM) dựa trên mật độ đỉnh để giải quyết độ nhạy của các tâm cụm ban đầu và cải thiện độ chính xác của phân cụm [8]. Tuy nhiên, một trong những hạn chế của thuật toán DP-FCM là các trung tâm cụm được chọn thủ công từ biểu đồ quyết định, không thể xác định dễ dàng. Ngoài ra, thuật toán FCM có hiệu suất yếu đối với dữ liệu nhiễu [9]. Nghiên cứu này nhằm mục đích cung cấp sự nâng cao của thuật toán DP-FCM. Đầu tiên, thuật toán possibilistic false *c*-means (PFCM) [10], là sự kết hợp giữa thuật toán FCM và thuật toán possibilistic *c*-means (PCM) [11], được sử dụng để thay thế FCM trong thuật toán DP-FCM. Thuật toán PFCM bao gồm các thuật ngữ khả năng và các thuật ngữ mờ vào hàm mục tiêu của nó để giải quyết nhiễu và

* Corresponding author.
E-mail addresses: rjkuo@mail.ntust.edu.tw (R.J. Kuo), naufal.alfareza@gmail.com (M.N. Alfareza), ntpquyen@dut.udn.vn (T.P.Q. Nguyen).

https://doi.org/10.1016/j.jestch.2023.101525
Received 7 February 2023; Received in revised form 25 July 2023; Accepted 4 September 2023
Available online 17 September 2023
2215-0986/© 2023 THE AUTHORS. Published by Elsevier BV on behalf of Karabuk University. This is an open access article under the CC BY-NC-ND license (http://creativecommons.org/licenses/by-nc-nd/4.0/).

dữ liệu ngoại lệ. Ngoài ra, thuật toán PFCM có thể bỏ qua bước chia tỷ lệ các giá trị đặc trưng, giúp thuật toán hiệu quả hơn đối với các tập dữ liệu lớn [10]. Để giải quyết vấn đề giải pháp tối ưu cục bộ, một số nghiên cứu đã kết hợp phân cụm với siêu dữ liệu để cải thiện hiệu suất phân cụm, chẳng hạn như thuật toán di truyền (GA), thuật toán đàn kiến và tổ chức bầy hạt [12–13]. Nhiều nghiên cứu đã sử dụng GA để giải quyết vấn đề phân cụm hoặc kết hợp GA với các phương pháp phân cụm theo nhiều cách khác nhau, chứng minh rằng chiến lược này có thể tránh rơi vào giải pháp tối ưu cục bộ để nâng cao hiệu suất phân cụm [14]. Theo Chehouri và cộng sự. [15], việc sử dụng GA có thể tạo ra kết quả tốt hơn và kết quả nhất quán hơn so với việc sử dụng *meta*-heuristic khác. Hơn nữa, GA có thể hội tụ đến một giải pháp tối ưu toàn cục [16]. Vì vậy, GA được lựa chọn nhằm mục đích cung cấp giải pháp tối ưu toàn cục. Vì vậy, nghiên cứu này đề xuất sự tích hợp giữa DPC, PFCM và GA, được đặt tên là thuật toán DP-GA-PFCM. Phân cụm DPC được sử dụng để tìm các trung tâm cụm ban đầu. Sau đó, GA được nhúng vào quá trình phân cụm để tìm ra đồng thời các tham số và tâm cụm tối ưu cho thuật toán PFCM. Các kết quả tối ưu từ GA sau đó được triển khai trên thuật toán PFCM để thu được kết quả phân cụm cuối cùng. DP-GA-PFCM được đề xuất dự kiến sẽ mang lại kết quả vượt trội do có một số điểm mới và đóng góp:

(1) Đây là sự kết hợp giữa các phương pháp phân cụm dựa trên mật độ và dựa trên mờ. (2) Phương pháp đề xuất có thể xử lý được dữ liệu nhiễu và dữ liệu ngoại lai. (3) Các tham số tối ưu và tâm cụm có thể được khai thác đồng thời. (4) Hiệu suất phân cụm được đo bằng nhiều chỉ số như độ chính xác, chỉ số rand được điều chỉnh (ARI) và thông tin lẫn nhau được chuẩn hóa (NMI).

Thuật toán DP-GA-PFCM đề xuất được triển khai trên nhiều bộ dữ liệu UCI Machine Learning Repository và kết quả được so sánh với các phương pháp phân cụm khác về độ chính xác, ARI và NMI. Ngoài ra, nghiên cứu này còn áp dụng thuật toán đề xuất để tiến hành phân đoạn thị trường cho một trường hợp nghiên cứu trong doanh nghiệp bán lẻ.

Các phần còn lại của nghiên cứu này được cấu trúc như sau. Phần 2 đưa ra một số bối cảnh chung của các tài liệu liên quan. Thuật toán đề xuất được trình bày ở Phần 3. Phần 4 trình bày kết quả đánh giá mô hình. Kết quả nghiên cứu điển hình được trình bày ở Phần 5. Cuối cùng, nhận xét kết luận được đưa ra ở Phần 6.

2. Tôi phê bình văn học

Phần này cung cấp khảo sát tài liệu liên quan đến nghiên cứu hiện tại bao gồm thuật toán mờ *c*-mean mật độ đỉnh, thuật toán mờ khả năng *c*- nghĩa và thuật toán di truyền.

2.1. Thuật toán c-mean mờ đỉnh mật độ

Thuật toán mờ *c*-means mật độ đỉnh là sự tích hợp của thuật toán DPC và FCM. Thuật toán này tính toán hai giá trị là mật độ cục bộ ρ_i của từng điểm dữ liệu *i* và khoảng cách δ_i của điểm *i* có mật độ cao hơn. Ngoài ra, có giả định rằng các trung tâm cụm được bao quanh bởi các lân cận có mật độ cục bộ thấp hơn và chúng ở khoảng cách tương đối lớn so với bất kỳ điểm nào có mật độ cục bộ cao hơn [17]. Quy trình của thuật toán DPFCM như sau:

Bước 1: Tính mật độ cục bộ. Mỗi bản ghi trong tập dữ liệu được tính mật độ cục bộ của nó bằng biểu thức. (1) cho giá trị rời rạc và phương trình. (2) cho giá trị liên tục. Mật độ cục bộ của điểm dữ liệu *i* cho $i = \{1, 2,\ldots, n\}$ cho giá trị rời rạc được xác định như sau:

$$\rho_i = \sum_j X^{(dis_{ij} - d_c)} \tag{1}$$

trong đó $X_{(x)} \int 1, x < 0\ 0, x \geq 0$. Đối với giá trị liên tục, hạt nhân Gaussian có chức năng
tion được sử dụng như sau:

$$\rho_i = \sum_{j \neq i} e^{-\left(\frac{dis_{ij}}{d_c}\right)^2} \tag{2}$$

trong đó d_c là khoảng cách cắt và dis_{ij} là khoảng cách Euclide giữa dữ liệu *i* và *j* với $i, j = \{1, 2,\ldots, n\}$.

Bước 2: Tính khoảng cách. Khoảng cách được tính từ mỗi điểm dữ liệu *i* cho $i = \{1, 2,\ldots, n\}$ với biểu thức. (3). Đối với điểm dữ liệu có mật độ cục bộ cao nhất, khoảng cách là $\max_j(dis_{ij})$.

$$\delta_i = \begin{cases} \min\limits_{j:\rho_j > \rho_i} (dis_{ij}) \\ \max_j(dis_{ij}) \end{cases} \tag{3}$$

Bước 3: Tạo biểu đồ quyết định. DPC sử dụng mật độ cục bộ làm trục x và khoảng cách làm trục y để xây dựng biểu đồ quyết định. Từ biểu đồ quyết định, một điểm dữ liệu có giá trị lớn cả về mật độ cục bộ và khoảng cách sẽ là tâm của cụm.

Bước 4: Khởi tạo ma trận thành viên. Ma trận thành viên được xác định bằng cách tạo ra các số ngẫu nhiên có tổng mỗi hàng bằng 1. Đầu ra của ma trận thành viên có thể được minh họa trong biểu thức. (4).

$$u_{ik} = \begin{bmatrix} u_{11} & \cdots & u_{1m} \\ \vdots & \ddots & \vdots \\ u_{n1} & \cdots & u_{nm} \end{bmatrix}; 1 \leq i \leq n; 1 \leq k \leq c, \tag{4}$$

uik thể hiện tư cách thành viên giữa các trung tâm cụm và điểm dữ liệu trong đó n là tổng dữ liệu và $j = 1,2,\ldots,m$ là số lượng thuộc tính. Mỗi điểm dữ liệu được chỉ định một mức độ thành viên cho mỗi cụm.

Bước 5: Tính trọng tâm. Sau khi xác định ma trận thành viên, hãy tính tâm cụm bằng biểu thức. (5).

$$V_k = \frac{\sum_{i=1}^{n} (u_{ik})^w X_{ij}}{\sum_{i=1}^{n} (u_{ik})^w}; 1 \leq i \leq n; 1 \leq k \leq c, \tag{5}$$

Từ phương trình. (5), các trung tâm cụm thu được bằng cách tính tổng của phép nhân giữa điểm dữ liệu với tư cách thành viên được hỗ trợ bởi trọng số xếp hạng *w* trong đó X_{ij} có nghĩa là điểm dữ liệu *i* với thuộc tính *j* và $w > 1$. Sau đó, giá trị được chia cho tổng của sức mạnh thành viên bởi *w*.

Bước 6: Tính hàm mục tiêu. Hàm mục tiêu tối thiểu của thuật toán FCM như trong biểu thức. (6) có thể thu được lặp đi lặp lại như sau:

$$P_t = \sum_{i=1}^{n} \sum_{k=i}^{c} \left(\left[\sum_{j=1}^{m} \left(X_{ij} - V_{kj}\right)^2 \right] (u_{ik})^w \right) \tag{6}$$

Bước 7: Cập nhật thành viên. Khi giá trị của hàm mục tiêu chưa đáp ứng ngưỡng được chấp nhận hoặc số lần lặp chưa đạt đến số lần lặp tối đa đã chỉ định, việc cập nhật thành viên có thể được thực hiện bằng phương trình. (7). Sau đó, tính toán lại tâm cụm như trong Bước 5, v.v.

$$u_{ik} = \frac{\left[\sum_{j=1}^{m} \left(X_{ij} - V_{kj}\right)^2 \right]^{\frac{-1}{w-1}}}{\sum_{i=1}^{c} \left[\sum_{j=1}^{m} \left(X_{ij} - V_{kj}\right)^2 \right]^{\frac{-1}{w-1}}} \tag{7}$$

2.2. Thuật toán c-mean mờ khả năng

Thuật toán c-means mờ khả năng (PFCM) là thuật toán được đề xuất bởi Pal et al. [10]. Thuật toán này là sự kết hợp giữa thuật toán FCM và thuật toán c-means (PCM). Thuật toán PFCM có hai loại tư cách thành viên, tư cách thành viên khả năng đo lường mức độ điển hình tuyệt đối của một điểm trong bất kỳ cụm cụ thể nào và tư cách thành viên mờ đo lường mức độ tương đối của các điểm chia sẻ

dọc theo cụm [18]. Quy trình cho thuật toán PFCM như sau: Bước 1: Khởi tạo ma trận phân vùng bằng phương trình. (4).

Bước 2: Tính ma trận điển hình. Bên cạnh ma trận mức độ thành viên hoặc ma trận phân vùng, cần có ma trận điển hình khi tính toán thuật toán PFCM. Ma trận điển hình là giá trị điển hình để xác định điểm dữ liệu nào thuộc cụm nào. Ma trận điển hình được tính bằng phương trình. (8) như sau:

$$t_{ik} = \left[1 + \left(\frac{b\left[\sum_{j=1}^{m}(X_{ij} - V_{kj})^2\right]}{\gamma_k}\right)^{\frac{1}{\eta-1}}\right]^{-1} \tag{8}$$

trong đó γ_k được tính như sau:

$$\gamma_k = K\frac{\sum_{i=1}^{n}\left((\mu_{ik})^w\left[\sum_{j=1}^{m}(X_{ij} - V_{kj})^2\right]\right)}{\sum_{i=1}^{n}(\mu_{ik})^w}, \tag{9}$$

Bước 3: Tính toán tâm cụm. Sau khi xác định được ma trận phân vùng và ma trận đặc trưng thì tính tâm cụm như sau:

$$V_k = \frac{\sum_{i=1}^{n}(a{\mu_{ik}}^w + b{t_{ik}}^\eta)X_{ij}}{\sum_{i=1}^{n}(a{\mu_{ik}}^w + b{t_{ik}}^\eta)} \tag{10}$$

Bước 4: Tính hàm mục tiêu. Hàm mục tiêu của PFCM được thể hiện trong biểu thức. (11).

$$P_t = \sum_{i=1}^{n}\sum_{k=1}^{c}(a{\mu_{ik}}^w + b{t_{ik}}^\eta)\left[\sum_{j=1}^{m}(X_{ij} - V_{kj})^2\right] + \sum_{k=1}^{c}\gamma_k\sum_{i=1}^{n}(1 - t_{ik})^\eta \tag{11}$$

Các hằng số 'a' và 'b' được định nghĩa tương ứng là tầm quan trọng tương đối của các giá trị thành viên mờ và giá trị điển hình trong hàm mục tiêu.

Bước 5: Cập nhật ma trận phân vùng và ma trận đặc trưng. Khi giá trị của hàm mục tiêu chưa đáp ứng ngưỡng được chấp nhận hoặc số lần lặp chưa đạt đến số lần lặp tối đa đã chỉ định, có thể thực hiện ma trận phân vùng cập nhật bằng phương trình. (12) và ma trận tính điển hình được cập nhật có thể được thực hiện bằng phương trình. (8). Sau đó, tính toán lại tâm cụm như trong Bước 3, v.v.

$$\mu_{ik} = \left[\sum_{j=1}^{m}(X_{ij} - V_{kj})^2\right]^{\frac{-1}{w-1}} / \sum_{i=1}^{c}\left[\sum_{j=1}^{m}(X_{ij} - V_{kj})^2\right]^{\frac{-1}{w-1}} \tag{12}$$

2.3. Thuật toán di truyền

Một trong những thuật toán metaheuristic nổi tiếng nhất là thuật toán di truyền (GA), dựa trên lý thuyết tiến hóa tự nhiên [19]. Trong GA, giá trị thích nghi của mỗi cá thể ảnh hưởng đến khả năng sinh sản. Chúng càng có nhiễm sắc thể tốt thì càng có nhiều khả năng được chọn cho thế hệ tiếp theo [19–20]. Haldurai và cộng sự. [20] đã mô tả quy trình chi tiết cho GA như sau:

Bước 1: Khởi tạo: Biểu diễn bài toán là một khái niệm quan trọng khi giải bằng GA. Một quần thể bao gồm một tập hợp các nhiễm sắc thể có vấn đề cần giải quyết.

Bước 2: Đánh giá: Bước này nhằm đo lường chức năng thích ứng của từng nhiễm sắc thể trong quần thể. Hàm thích ứng là thước đo hiệu suất của một cá nhân giống với hàm mục tiêu của bài toán được tối ưu hóa. Hàm mục tiêu có thể là cực tiểu hóa hoặc cực đại hóa. Giá trị thích hợp càng cao hoặc càng thấp thì khả năng sống sót của cá thể đó càng cao.

Bước 3: Tuyển chọn: Tiến hành chọn lọc các nhiễm sắc thể trong quần thể có giá trị thích nghi tốt nhất. Nhiễm sắc thể đáp ứng các tiêu chí phù hợp đã xác định trước sẽ có nhiều khả năng được chọn cho thế hệ tiếp theo. Một số phương pháp lựa chọn thường được sử dụng bao gồm lựa chọn bánh xe roulette, phân công thể lực dựa trên cấp bậc, lựa chọn giải đấu và chủ nghĩa tinh hoa.

Bước 4: Trao đổi chéo: Đây là quá trình kết hợp nhiều giá trị trong một cá thể để tạo ra một cá thể mới. Nó bắt đầu bằng việc chọn một cặp cá thể từ quần thể, sau đó nếu nó đáp ứng được tỷ lệ trao đổi chéo đã chỉ định thì việc trao đổi chéo sẽ được thực hiện. Một số phương pháp được sử dụng trong lai ghép là ghép chéo một điểm, ghép chéo hai điểm và ghép chéo điểm thống nhất.

Bước 5: Đột biến: Đây là quá trình thay đổi giá trị của một cá nhân tại một vị trí nhất định. Quá trình đột biến được thực hiện bằng cách thay thế một giá trị được chọn ngẫu nhiên trong nhiễm sắc thể bằng một giá trị ngẫu nhiên mới. Ngược lại, trong bài toán số nhị phân, những cá thể đạt tỷ lệ đột biến sẽ được thay đổi từ 0 thành 1 hoặc ngược lại.

Bước 6: Quay lại bước 2. Thuật toán sẽ dừng khi đạt đến số thế hệ được chỉ định hoặc đã đạt đến giá trị thích hợp có thể chấp nhận được.

3. Phương pháp

Một kỹ thuật phân cụm mới, kết hợp các thuật toán DPC, GA và PFCM (ký hiệu là DP-GA-PFCM) được đề xuất để cải thiện hiệu suất phân cụm. Thuật toán DP-GA-PFCM được đề xuất cũng có thể giải quyết độ nhạy của các trung tâm cụm ban đầu cũng như có thể xử lý dữ liệu nhiễu và dữ liệu ngoại lệ. Như đã đề cập trước đó, thuật toán PFCM có thể xử lý nhiễu và các giá trị ngoại lệ dựa trên thuật ngữ đặc trưng của nó. Phương pháp đề xuất sử dụng khái niệm đỉnh mật độ để thu được tâm cụm trước tiên. Sau đó, các trung tâm cụm được tiết lộ sẽ được sử dụng làm khởi tạo thuật toán PFCM. Tuy nhiên, các tham số của thuật toán PFCM không dễ xác định và các trung tâm cụm lấy từ kết quả đỉnh mật độ có thể không phải lúc nào cũng cho kết quả phân cụm chính xác nhất. Do đó, GA được sử dụng để tìm các tham số và tâm cụm tối ưu cho thuật toán PFCM. Phần dưới đây sẽ giải thích chi tiết hơn về phương pháp DP-GA-PFCM được đề xuất.

3.1. Tiền xử lý dữ liệu

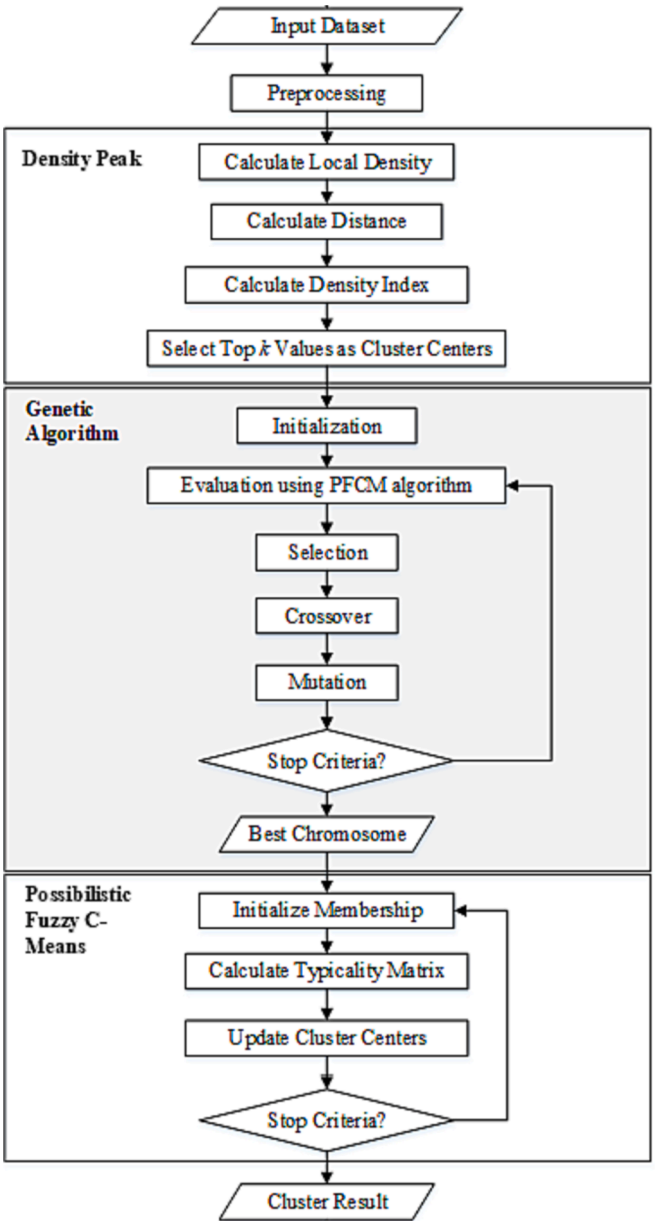
Bộ chia tỷ lệ MinMax được sử dụng để xử lý trước tập dữ liệu trước khi phân tích. Thang đo này thay đổi giá trị của từng thuộc tính thành một phạm vi từ 0 đến 1. Giá trị được chia tỷ lệ, X_{scaled}, có thể thu được như sau:

$$X_{scaled} = \frac{X_i - min(x)}{max(x) - min(x)} \tag{13}$$

trong đó X_i đại diện cho giá trị ban đầu, min*(x)* đại diện cho giá trị tối thiểu của tất cả dữ liệu thuộc tính và max*(x)* đại diện cho giá trị tối đa của tất cả dữ liệu thuộc tính.

3.2. Thuật toán DP-GA-PFCM được đề xuất

Hình 1 thể hiện khung thuật toán của thuật toán DP-GA-PFCM được đề xuất, bao gồm ba giai đoạn. Trong giai đoạn đầu tiên, DPC được sử dụng để xác định các trung tâm cụm ban đầu dựa trên biểu đồ quyết định, trong đó biểu đồ quyết định cũng có thể xác định sự hiện diện của các giá trị ngoại lệ. Trung tâm cụm bao gồm các điểm dữ liệu có mật độ cao nhất. Tuy nhiên, các trung tâm cụm thu được có thể không tạo ra kết quả khả quan trên một số tập dữ liệu vì nó cho phép tồn tại các giá trị ngoại lệ sẽ ảnh hưởng đến kết quả phân cụm. Để khắc phục vấn đề về các ngoại lệ, thuật toán PFCM được áp dụng trong đó các tâm cụm thu được từ DPC được sử dụng để khởi tạo thuật toán PFCM. Vì không dễ để xác định các tham số tối ưu cho PFCM nên chúng tôi sử dụng GA để có được các trung tâm cụm tối ưu và bốn tham số bắt buộc trong thuật toán PFCM, tức là a, b, w, η. Thuật toán PFCM được nhúng bên trong GA và mục đích của nó chỉ là tính toán sự phù hợp của nhiễm sắc thể. Do đó, thuật toán PFCM chỉ chạy một lần lặp cho mỗi thế hệ GA. Sau đó, ở giai đoạn thứ ba, thuật toán PFCM được triển khai lặp đi lặp lại để tinh chỉnh kết quả từ GA. Tóm lại, sau khi lấy được các tâm cụm ban đầu từ cụm đỉnh mật độ, sau đó được tối ưu hóa bằng cách sử dụng GA liên quan đến thao tác thuật toán PFCM để tính toán mức độ phù hợp, thuật toán PFCM được thực hiện để thu được



Hình. 1. Khung thuật toán DP-GA-PFCM.

kết quả phân cụm cuối cùng. Lưu ý rằng việc triển khai PFCM trong giai đoạn thứ ba tương tự như phiên bản gốc ở cách nó cập nhật thành viên mờ và tính điển hình từ các trung tâm cụm tối ưu thu được từ kết quả của GA. Đặc biệt, tính điển hình giờ đây được tự động tăng lên theo γ_k trong biểu thức. (9).

Các trung tâm cụm được sử dụng cho quần thể ban đầu của GA được lấy từ kết quả phân cụm đỉnh mật độ. Hình 2 minh họa sự biểu diễn của nhiễm sắc thể. Số lượng trung tâm cụm phụ thuộc vào số lượng cụm, n và số lượng thuộc tính, m, trong dữ liệu được sử dụng. Ngoài ra, a, b, w và eta là bốn tham số bắt buộc trong thuật toán PFCM trong đó các giá trị này lớn hơn 0.

Các quy trình của thuật toán DP-GA-PFCM được đề xuất được liệt kê như sau:

V_{11}	V_{12}	...	Vmn	a	b	w	eta

Hình. 2. Biểu hiện của nhiễm sắc thể.

Bước 1: Nhập và xử lý trước tập dữ liệu bằng phương trình. (13).

Bước 2: Tính mật độ cục bộ và khoảng cách bằng phương trình. tương ứng là 2–3.

Bước 3: Tính chỉ số khoảng cách bằng cách nhân mật độ cục bộ và khoảng cách.

Bước 4: Chọn các giá trị k hàng đầu làm tâm cụm ban đầu.

Bước 5: Khởi tạo quần thể theo số lượng nhiễm sắc thể.

Bước 6: Đánh giá các nhiễm sắc thể trong quần thể để giảm thiểu tổng sai số bình phương trong cụm bằng thuật toán PFCM (Phương trình (6).

Bước 7: Thực hiện lựa chọn bằng cơ chế lựa chọn bánh xe roulette.

Bước 8: Thực hiện quá trình lai ghép và đột biến.

Nhiễm sắc thể bao gồm hai phần, tức là các tham số và trung tâm cụm của PFCM, tất cả đều được biểu thị bằng giá trị thực. Trao đổi chéo một điểm hoặc trao đổi chéo đa điểm truyền thống không phù hợp vì các gen trao đổi cần phải phù hợp với từng phần cụ thể của nhiễm sắc thể. Do đó, nghiên cứu này sử dụng chức năng trao đổi chéo của GA được mã hóa thực [21] để tạo ra nhiễm sắc thể mới, được biểu diễn như sau:

$$O_1 = rP_1 + (1-r)P_2, \tag{14}$$

$$O_2 = rP_2 + (1-r)P_1, \tag{15}$$

trong đó O_1 và O_2 là hai nhiễm sắc thể con được tạo ra từ hai nhiễm sắc thể bố mẹ P_1 và P_2, r là số ngẫu nhiên từ 0 và 1.

Tương tự, quá trình đột biến được thực hiện dựa trên hàm sau [21]:

$$O_i = P_i + s_i \times r_i \times q_i \tag{16}$$

trong đó $q_i = 2^{-uk}$, s_i và u là hai số ngẫu nhiên trong đó $s_i \in \{-1, +1\}$ và $u \in [0, 1]$, r_i là phạm vi đột biến được đặt ở mức 10% làm tiêu chuẩn và k là độ chính xác đột biến ($k \in \{4, 5, \cdots 20\}$).

Bước 9: Lặp lại các bước 6–8 và dừng lại nếu thỏa mãn số lần lặp tối đa để thu được các tâm và tham số cụm tối ưu cho PFCM.

Bước 10: Khởi tạo hoặc cập nhật tư cách thành viên bằng phương trình. (7) dựa trên tâm cụm thu được từ Bước 9.

Bước 11: Tính ma trận điển hình bằng phương trình. (8).

Bước 12: Cập nhật trung tâm cụm bằng phương trình. (10).

Bước 13: Lặp lại các bước 10–12 và dừng nếu đạt đến số lần lặp tối đa hoặc khi chênh lệch trong hàm mục tiêu đã đạt đến ngưỡng được chấp nhận.

Mã giả của thuật toán đề xuất được xác định như sau: **Thuật toán 1. Thuật toán DP-GA-PFCM**

Đầu vào: k (số cụm), *MAX_ITER* (số lần lặp tối đa) **Đầu ra:** L (bộ k nhãn cụm)

Bước Tính mật độ cục bộ Tính khoảng cách Tính chỉ số khoảng cách Chọn các giá trị top k Khởi tạo quần thể **while** $i <$ *MAX_ITER*, **do** Tính toán mức độ phù hợp bằng thuật toán PFCM Lựa chọn Đột biến chéo **kết thúc trong khi**Chọn nhiễm sắc thể tốt nhất Khởi tạo thành viên **while** $j <$ *MAX_ITER*, **do** Tính ma trận điển hình Cập nhật trung tâm cụm Cập nhật thành viên **kết thúc while** Báo cáo L dưới dạng tập hợp các nhãn cụm

3.3. Đo lường hiệu suất

Đo lường hiệu suất được thực hiện để xác nhận xem thuật toán đề xuất có mang lại kết quả tốt hơn hay không. Có ba phép đo được sử dụng là độ chính xác, chỉ số Rand được điều chỉnh (ARI) và thông tin lẫn nhau được chuẩn hóa (NMI). Để định lượng độ chính xác, lượng dữ liệu chính xác trong mỗi cụm được chia cho tổng lượng dữ liệu. Độ chính xác có thể được định nghĩa là:

$$Accuracy = \frac{\sum_{i=1}^{k} \max(a_i)}{n} \tag{17}$$

trong đó max(a_i) biểu thị số lượng điểm dữ liệu được dự đoán chính xác cả trong cụm i^{th} và lớp thực tương ứng của nó, và n là tổng số điểm dữ liệu.

ARI đo lường sự giống nhau giữa các nhóm bằng cách xem xét tất cả các cặp mẫu và đếm các cặp được gán cho các cụm giống nhau hoặc khác nhau. Tính toán ARI có thể được định nghĩa là:

$$ARI = \frac{RI - ExpectedRI}{\max(RI) - ExpectedRI}, \tag{18}$$

trong đó *RI* biểu thị sự tương đồng giữa hai cụm bằng cách xem xét tất cả các cặp mẫu, *RI dự kiến* biểu thị giá trị trung bình của mỗi cụm *RI*, và max*(RI)* biểu thị giá trị tối đa của mỗi cụm RI.

NMI là một phép đo khác thường được sử dụng để đo hiệu suất của các thuật toán phân cụm. NMI đo lường lượng thông tin mà một biến có thể nhận được từ các biến khác đã được chuẩn hóa. Giá trị NMI nằm trong khoảng 0 và 1. Nếu bằng 0 thì có nghĩa là không có thông tin lẫn nhau hoặc hai biến độc lập với nhau. Nếu giá trị là 1 thì hai biến phụ thuộc lẫn nhau. Tính toán NMI có thể được định nghĩa là:

$$NMI = I(X, Y)/\sqrt{H(X)H(Y)} \tag{19}$$

trong đó *I(X, Y)* đại diện cho lượng thông tin lẫn nhau, còn *H (X)* và *H(Y)* đại diện cho entropy của thông tin cho biến X và Y.

4. Kết quả thực nghiệm

Phần này trình bày các kết quả thực nghiệm nhằm đánh giá hiệu năng của thuật toán đề xuất. Tất cả các thuật toán đều được mã hóa bằng Python và chạy trên máy tính Windows 10 với bộ xử lý Intel Core i7 và RAM 20 GB.

4.1. Bộ dữ liệu

Để đánh giá hiệu suất của thuật toán đề xuất, nghiên cứu này đã sử dụng 14 bộ dữ liệu chuẩn từ kho lưu trữ máy học UCI (https://archive.ics.uci.edu/ml/). Bảng 1 cho thấy mô tả của từng tập dữ liệu được sử dụng, trong đó *K* đại diện cho số lượng cụm được xác định trước, *F* đại diện cho số lượng thuộc tính và *N* đại diện cho số lượng bản ghi. Do thuật toán đề xuất tập trung vào việc khắc phục sự hiện diện của nhiễu và tập dữ liệu ngoại lệ, nên một số tập dữ liệu chứa các ngoại lệ là Ngọn lửa, Rượu, Thủy tinh, Ecoli, Hợp chất, Hạt giống, Mô vú và Pima.

Bảng 1 Mô tả các tập dữ liệu.

No.	Dataset	*K*	*F*	*N*
1.	Iris	3	4	150
2.	Flame	2	2	240
3.	Jain	2	2	373
4.	Wine	3	13	178
5.	Glass	7	9	214
6.	Ecoli	8	7	336
7.	Compound	6	2	399
8.	Seed	3	7	210
9.	Breast Tissue	6	9	106
10.	Aggregation	7	2	788
11.	Pima	2	8	768
12	Room Occupancy	2	7	20,560
13	Rice	2	7	3810
14	Wifi	4	7	2000

4.2. Thiết lập thông số

Về bản chất, thuật toán đề xuất là kết quả của việc kết hợp ba phương pháp: DPC, PFCM và metaheuristics. Tuy nhiên, mỗi phương pháp đều yêu cầu các tham số của nó. Khoảng cách cắt 2% được đặt cho DPC. Thuật toán PFCM cũng có các tham số của nó. Vì các tham số này khó xác định nên phương pháp metaheuristic được sử dụng để tìm ra sự kết hợp hiệu quả nhất của các tham số này. Tuy nhiên, siêu dữ liệu đòi hỏi phải xác định một số thông số. Trong nghiên cứu này, GA là phương pháp phỏng đoán *meta* chính được sử dụng để kết hợp với DPC nhằm tìm ra các trung tâm cụm tối ưu và các tham số tối ưu cho thuật toán PFCM. Ngoài ra, một số *meta*-heuristic khác như tối ưu hóa nhóm hạt (PSO) [22], thuật toán sin-cosine (SCA) [23] và Điều tra dựa trên pháp y (FBI) [24] cũng được sử dụng để đánh giá tính hiệu quả của *meta*- phương pháp heuristic. Do mục đích so sánh, quy mô tổng thể và số lần lặp tối đa là như nhau đối với tất cả các siêu dữ liệu. Số lần lặp tối đa đang được sử dụng làm tiêu chí để dừng.

Trong siêu dữ liệu, không có một giá trị tốt nhất nào đại diện cho các tham số được sử dụng. Một thiết kế giai thừa chung được sử dụng để kiểm tra một số tham số ở các cấp độ khác nhau nhằm khám phá sự kết hợp tối ưu. Đối với GA, hai giá trị khác nhau cho tỷ lệ chéo và tỷ lệ đột biến được chọn trong khoảng từ 0 đến 1. Nói chung, tỷ lệ chéo cao trong khi tỷ lệ đột biến thấp. Hassanat và cộng sự. [20] đã chỉ ra rằng tỷ lệ chéo và tỷ lệ đột biến là hai yếu tố quan trọng trong việc tìm kiếm GA. Ngoài ra, quy mô quần thể là thông số quan trọng nhất ảnh hưởng đến việc lựa chọn tỷ lệ lai ghép và tỷ lệ đột biến. Trong khi tỷ lệ đột biến là đáng tin cậy nhất ở quy mô quần thể nhỏ, thì tỷ lệ chéo lại thay đổi tùy theo quy mô quần thể. Tuy nhiên, quy mô dân số vừa phải sẽ giúp hoạt động di truyền, bao gồm các cơ chế chọn lọc, lai ghép và đột biến, hoạt động tốt. Vì vậy, để giảm số lượng các yếu tố có thể dẫn đến giảm độ phức tạp của thiết kế giai thừa, quy mô quần thể không được xem xét trong thử nghiệm. Kích thước quần thể và số lần lặp được đặt tương ứng là 80 và 100 sau một số thử nghiệm cho tất cả các thuật toán.

Tương tự như vậy, PSO sử dụng các trọng số và hằng số quán tính khác nhau. Kết quả là, GA và PSO mỗi bên thực hiện bốn thí nghiệm với các tổ hợp tham số khác nhau trong 30 lần. Mức độ của từng yếu tố trong thí nghiệm được trình bày trong Bảng 2. Dựa trên các nghiên cứu trước đây sử dụng GA và PSO trong phân cụm [25–27], tỷ lệ chéo là 0,7 và 0,8, trong khi tỷ lệ đột biến là 0,01 và 0,03. Đối với PSO, hai hằng số c1 và c2 được đặt bằng nhau ở hai mức, tức là 1 và 2, trong khi hai mức trọng lượng quán tính bắt đầu bằng 0,4 và 0,5 và tăng dần lên tương ứng là 0,9 và 0,8. Độ chính xác của phân cụm được sử dụng để đánh giá hiệu suất của từng kết hợp. Bạn có thể xem kết quả về độ chính xác trung bình tương ứng của GA và PSO trong Bảng 3 và Bảng 4. Sau đó, sự kết hợp của các tham số được thực hiện để tạo ra giá trị trung bình cao nhất từ 14 bộ dữ liệu chuẩn được hiển thị trong Bảng 5.

Bảng 2 Thông số điều chỉnh.

	Level 1	Level 2
Crossover rate	0.7	0.8
Mutation rate	0.01	0.03
Inertia weight	[0.4 0.9]	[0.5 0.8]
Constants ($c_1 = c_2$)	1	2

Bảng 3 Độ chính xác trung bình của GA trên các tham số điều chỉnh khác nhau.

Crossover rate	0.7		0.8	
Mutation rate	0.01	0.03	0.01	0.03
Iris	0.919	0.908	0.914	0.912
Flame	0.846	0.848	0.848	0.845
Jain	0.878	0.871	0.882	0.876
Wine	0.943	0.948	0.955	0.949
Glass	0.575	0.569	0.581	0.565
Ecoli	0.754	0.750	0.777	0.763
Seed	0.896	0.898	0.900	0.894
Aggregation	0.910	0.906	0.910	0.909
Compound	0.814	0.836	0.845	0.834
Breast Tissue	0.611	0.608	0.615	0.615
Pima	0.668	0.669	0.710	0.677
Room Occupancy	0.862	0.874	0.896	0.885
Rice	0.896	0.890	0.924	0.918
Wifi	0.931	0.926	0.963	0.943

Bảng 4 Độ chính xác trung bình của PSO trên các thông số điều chỉnh khác nhau.

Initial weight	[0.5, 0.8]		[0.4, 0.9]	
Constants ($c_1 = c_2$)	1	2	1	2
Iris	0.892	0.889	0.891	0.899
Flame	0.843	0.843	0.842	0.843
Jain	0.882	0.881	0.881	0.881
Wine	0.950	0.951	0.950	0.951
Glass	0.571	0.558	0.554	0.561
Ecoli	0.789	0.782	0.783	0.792
Seed	0.890	0.890	0.891	0.890
Aggregation	0.904	0.904	0.904	0.903
Compound	0.840	0.840	0.839	0.844
Breast Tissue	0.574	0.564	0.568	0.574
Pima	0.664	0.662	0.663	0.662
Room Occupancy	0.865	0.861	0.869	0.873
Rice	0.901	0.896	0.913	0.920
Wifi	0.923	0.912	0.927	0.929

Bảng 5 Thiết lập thông số.

	GA	PSO	SCA	FBI
Population size	80	80	80	80
Maximum iteration	100	100	100	100
Crossover rate	0.8	–	–	–
Mutation rate	0.1	–	–	–
Inertia weight	–	[0.4 0.9]	–	–
Constants (c1 = c2)	–	2	–	–

4.3. Kết quả thực nghiệm

Trong nghiên cứu này, thí nghiệm được chia thành hai giai đoạn. Giai đoạn đầu tiên là so sánh năm thuật toán phân cụm mà không sử dụng phương pháp metaheuristic. Giai đoạn này nhằm mục đích xác định xem thuật toán DP-PFCM có ưu việt hơn thuật toán K-means, thuật toán FCM, thuật toán PFCM và thuật toán DP-FCM hay không. Giai đoạn thứ hai là so sánh các thuật toán phân cụm được đề xuất với các thuật toán khác bằng cách sử dụng siêu dữ liệu. Giai đoạn này nhằm mục đích xác định thuật toán metaheuristic nào vượt trội hơn các thuật toán khác trong số các thuật toán GA, PSO, SCA và FBI để có được kết quả tốt hơn hoặc ổn định hơn.

4.3.1. Kết quả thử nghiệm giai đoạn đầu

Bảng 6, Bảng 7 và Bảng 8 lần lượt trình bày các kết quả thử nghiệm giai đoạn đầu về độ chính xác, ARI và NMI. Những kết quả này là giá trị trung bình của 30 lần thực hiện. Giá trị cao của mỗi hiệu suất về cơ bản cho thấy hiệu suất tốt hơn. Các số trong cột biểu thị thuật toán được sử dụng, trong đó (1) đại diện cho *K*-means, (2) đại diện cho FCM, (3) đại diện cho PFCM, (4) đại diện cho DP-FCM và (5) đại diện cho DP-PFCM. Mỗi thước đo hiệu suất cho tập dữ liệu được xếp hạng trong đó điểm cao nhất sẽ được xếp hạng đầu tiên và điểm nhỏ nhất sẽ được xếp hạng cuối cùng.

Sau khi được xếp hạng dựa trên giá trị cao nhất, các giá trị sẽ được cộng vào mỗi cột để xác định thuật toán nào hoạt động tốt hơn. Như có thể thấy trong Bảng 6, Bảng 7 và Bảng 8, tổng giá trị xếp hạng của thuật toán (5) hoặc thuật toán DP-PFCM là nhỏ nhất so với các thuật toán khác về độ chính xác, ARI và NMI. Thuật toán này hoạt động tốt hơn trên 9 trên 14 tập dữ liệu là Iris, Flame, Wine, Glass, Seed, Breast Tissue, Pima, Room Occupancy và Wifi. Có thể kết luận rằng DP-PFCM có thể cung cấp kết quả tốt hơn về độ chính xác, ARI và NMI. Ngoài ra, Hình 3 mô tả tổng thứ hạng của DP-PFCM được đề xuất và các thuật toán điểm chuẩn khác trên 14 bộ dữ liệu được thử nghiệm trong giai đoạn đầu của thử nghiệm để hiển thị rõ hơn. Tổng thứ hạng nhỏ nhất cho thấy hiệu suất tốt nhất.

Để xác định liệu có sự khác biệt đáng kể giữa các thuật toán hay không, một thử nghiệm thống kê được tiến hành dựa trên kết quả thử nghiệm đối với ba thước đo hiệu suất. Trong nghiên cứu này, mức ý nghĩa được đặt ở mức 5%. Tiêu chí ra quyết định trong bài kiểm tra này là giá trị *p* hoặc tiệm cận. Đúng vậy. (2 đuôi)$\leq$0,05 thì H_0 bị bác bỏ, ngược lại H_1 bị bác bỏ. Là bước đầu tiên trong việc xác định thử nghiệm thích hợp, thử nghiệm tính chuẩn được thực hiện trước để xác định xem dữ liệu có được phân phối chuẩn hay không. Phần lớn các kết quả kiểm tra tính quy phạm cho thấy dữ liệu không được phân phối bình thường. Do đó, bài kiểm tra Kruskal-Wallis được tiến hành có thể đánh giá sự khác biệt giữa các nhóm bằng cách ước tính sự khác biệt về thứ hạng giữa các nhóm. Thử nghiệm này là thử nghiệm không tham số, có nghĩa là không có phân phối hoặc thử nghiệm không cần tính quy phạm

Bảng 6 Kết quả thử nghiệm độ chính xác giai đoạn đầu.

Dataset	Average Accuracy					Rank				
	(1)	(2)	(3)	(4)	(5)	(1)	(2)	(3)	(4)	(5)
Iris	0.886	0.892	0.899	0.892	0.908	5	3	2	4	1
Flame	0.843	0.848	0.853	0.851	0.855	5	4	2	3	1
Jain	0.883	0.884	0.878	0.883	0.879	3	1	5	2	4
Wine	0.944	0.944	0.945	0.941	0.952	4	3	2	5	1
Glass	0.546	0.556	0.564	0.558	0.566	5	4	2	3	1
Ecoli	0.813	0.823	0.822	0.831	0.817	5	2	3	1	4
Seed	0.891	0.899	0.895	0.898	0.899	5	2	4	3	1
Aggregation	0.911	0.898	0.905	0.908	0.909	1	5	4	3	2
Compound	0.813	0.830	0.853	0.832	0.838	5	4	1	3	2
Breast Tissue	0.556	0.600	0.600	0.557	0.611	5	3	2	4	1
Pima	0.665	0.668	0.672	0.669	0.681	5	4	2	3	1
Room Occupancy	0.810	0.815	0.852	0.857	0.862	5	4	3	2	1
Rice	0.905	0.905	0.907	0.919	0.912	4	4	3	1	2
Wifi	0.901	0.911	0.907	0.939	0.945	5	3	4	2	1
Sum of Rank						62	46	39	39	23

Table 7
First-stage ARI experimental result.

Dataset	Average ARI					Rank				
	(1)	(2)	(3)	(4)	(5)	(1)	(2)	(3)	(4)	(5)
Iris	0.714	0.727	0.742	0.725	0.759	5	3	2	4	1
Flame	0.469	0.481	0.497	0.492	0.501	5	4	2	3	1
Jain	0.579	0.584	0.564	0.581	0.569	3	1	5	2	4
Wine	0.836	0.837	0.839	0.827	0.858	4	3	2	5	1
Glass	0.169	0.159	0.183	0.173	0.194	4	5	2	3	1
Ecoli	0.457	0.413	0.433	0.395	0.419	1	4	2	5	3
Seed	0.706	0.724	0.719	0.723	0.729	5	2	4	3	1
Aggregation	0.720	0.684	0.692	0.708	0.683	1	4	3	2	5
Compound	0.524	0.531	0.564	0.531	0.547	5	3	1	3	2
Breast Tissue	0.277	0.301	0.327	0.336	0.393	5	4	3	2	1
Pima	0.087	0.108	0.112	0.109	0.115	5	4	2	3	1
Room Occupancy	0.731	0.698	0.712	0.748	0.739	3	5	4	1	2
Rice	0.831	0.830	0.792	0.864	0.853	3	4	5	1	2
Wifi	0.702	0.832	0.856	0.858	0.861	5	4	3	2	1
Sum of Rank						54	50	40	39	26

Table 8
First-stage NMI experimental result.

Dataset	Average NMI					Rank				
	(1)	(2)	(3)	(4)	(5)	(1)	(2)	(3)	(4)	(5)
Iris	0.740	0.741	0.750	0.742	0.764	5	4	2	3	1
Flame	0.423	0.438	0.447	0.446	0.455	5	4	2	3	1
Jain	0.522	0.543	0.535	0.545	0.533	5	2	3	1	4
Wine	0.822	0.826	0.825	0.813	0.842	4	2	3	5	1
Glass	0.331	0.312	0.343	0.329	0.353	3	5	2	4	1
Ecoli	0.604	0.587	0.609	0.580	0.596	2	4	1	5	3
Seed	0.680	0.689	0.684	0.688	0.701	5	2	4	3	1
Aggregation	0.843	0.814	0.834	0.830	0.836	1	5	3	4	2
Compound	0.697	0.699	0.719	0.701	0.708	5	4	1	3	2
Breast Tissue	0.514	0.529	0.543	0.519	0.562	4	3	2	5	1
Pima	0.044	0.063	0.071	0.066	0.070	5	4	1	3	2
Room Occupancy	0.802	0.647	0.626	0.798	0.843	2	4	5	3	1
Rice	0.865	0.852	0.860	0.927	0.876	3	5	4	1	2
Wifi	0.777	0.827	0.842	0.877	0.900	5	4	3	2	1
Sum of Rank						54	52	36	45	23

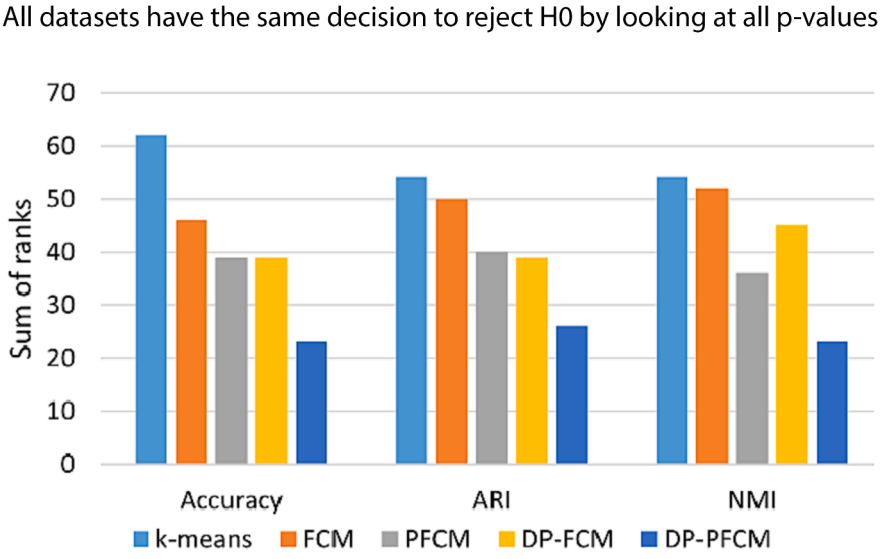


Fig. 3. The sum of ranks in the first stage of the experiment.

assumption. The null and alternative hypotheses for the Kruskal-Wallis test are as follows: H_0: There is no difference based on the algorithm used, and H_1: There is at least one different algorithm based on the algorithms used. Table 9 shows the summary of *p*-value results for three performance measures for each dataset.

All datasets have the same decision to reject H_0 by looking at all *p*-values that were less than 0.05. Therefore, it can be concluded that There is at least one different algorithm based on the algorithms used for the results in terms of accuracy, ARI, and NMI, respectively. A post-hoc analysis is performed to determine which algorithm differs from the

Bảng 9 Kiểm tra thống kê giai đoạn đầu.

Dataset	*p*-value Accuracy	ARI	NMI	Decision
Iris	<0.001	<0.001	<0.001	Reject H_0
Flame	<0.001	<0.001	<0.001	Reject H_0
Jain	<0.001	<0.001	<0.001	Reject H_0
Wine	0.002	<0.001	<0.001	Reject H_0
Glass	<0.001	<0.001	<0.001	Reject H_0
Ecoli	<0.001	<0.001	<0.001	Reject H_0
Seed	<0.001	<0.001	<0.001	Reject H_0
Aggregation	<0.001	<0.001	<0.001	Reject H_0
Compound	<0.001	<0.001	<0.001	Reject H_0
Breast Tissue	<0.001	<0.001	<0.001	Reject H_0
Pima	0.004	<0.001	<0.001	Reject H_0
Room Occupancy	<0.001	<0.001	<0.001	Reject H_0
Rice	<0.001	<0.001	<0.001	Reject H_0
Wifi	<0.001	<0.001	<0.001	Reject H_0

người khác. Trên mỗi cặp nhóm, các bài kiểm tra hậu kỳ Dunn-Bonferroni đã được thực hiện. Bảng 10 cho thấy kết quả kiểm tra Dunn-Bonferroni cho từng cặp nhóm về độ chính xác, ARI và NMI. Sự khác biệt đáng kể giữa hai thuật toán được thể hiện ở giá trị $p \leq 0{,}05$ và được đánh dấu "*". Ngược lại, giá trị $p > 0{,}05$ và dấu "-" cho thấy không có sự khác biệt đáng kể giữa hai thuật toán. Nhìn chung, thuật toán DP-PFCM có sự khác biệt đáng kể so với các thuật toán khác về độ chính xác, ARI và NMI cho hầu hết các bộ dữ liệu chuẩn. Thuật toán DP-PFCM vượt trội hơn về mặt thống kê so với các thuật toán khác vì nó có thứ hạng thấp nhất trong số tất cả các thuật toán. Điều này chứng tỏ rằng việc sử dụng phân cụm đỉnh mật độ có thể giải quyết được độ nhạy của các tâm cụm ban đầu, hiệu quả hơn so với việc khởi tạo các số ngẫu nhiên.

4.3.2. Kết quả thực nghiệm giai đoạn 2

Thuật toán DP-PFCM là thuật toán hiệu quả nhất trong giai đoạn đầu. Do khó khăn trong việc xác định các tham số của thuật toán PFCM, siêu dữ liệu được sử dụng để xác định sự kết hợp tối ưu giữa tâm cụm và các tham số mang lại kết quả ổn định. Bảng 11, Bảng 12 và Bảng 13 lần lượt thể hiện kết quả thử nghiệm giai đoạn hai về độ chính xác, ARI và NMI. Những kết quả này là giá trị trung bình của 30 lần thực hiện. Các thuật toán điểm chuẩn được ký hiệu như sau: A1 đại diện cho DP-PFCM, A2 đại diện cho DP-GA-PFCM, A3 đại diện cho DP-PSO-PFCM, A4 đại diện cho DP-SCA-PFCM và A5 đại diện cho DP-FBI-PFCM. Ngoài ra, nghiên cứu này còn so sánh kết quả của phương pháp đề xuất với hai thuật toán chuẩn là thuật toán di truyền-dựa trên thuật toán mờ có trọng số mờ trực giác c-có thứ tự-thuật toán trung bình (GA-IFWCOM) [14] và thuật toán có nghĩa mờ dựa trên thuật toán sin cosine *c* (SCA-FPCOM) [28], được ký hiệu lần lượt là A6 và A7 trong Bảng 11-13. Hơn nữa, các số trong dấu ngoặc đơn () trong các Bảng này hiển thị thứ hạng tương ứng của kết quả của chúng, so với bảy thuật toán. Giống nhau

Bảng 10 So sánh theo cặp giai đoạn đầu.

Pair		Accuracy				AR				NMI			
Dataset		K-means vs. DP-PFCM	FCM vs. DP-PFCM	PFCM vs. DP-PFCM	DP-FCM vs. DP-PFCM	K-means vs. DP-PFCM	FCM vs. DP-PFCM	PFCM vs. DP-PFCM	DP-FCM vs. DP-PFCM	K-means vs. DP-PFCM	FCM vs. DP-PFCM	PFCM vs. DP-PFCM	DP-FCM vs. DP-PFCM
Iris		<0.001*	<0.001*	0.038*	0.002*	<0.001*	<0.001*	0.003*	0.002*	<0.001*	<0.001*	<0.001*	<0.001*
Flame		0.001*	0.033*	1.000	1.000	<0.001*	0.026*	1.000	1.000	<0.001*	0.028*	1.000	1.000
Jain		0.111	0.002*	0.956	<0.001*	0.399	0.002*	1.000	<0.001*	0.038*	0.008*	1.000	0.001*
Wine		0.002*	1.000	0.020*	0.072	0.001*	0.369	0.004*	0.011*	0.001*	0.250	0.003*	0.009*
Glass		<0.001*	<0.001*	1.000	0.027*	<0.001*	<0.001*	0.897	<0.001*	0.001*	<0.001*	1.000	<0.001*
Ecoli		1.000	0.745	0.337	<0.001*	0.011*	0.427	0.237	0.014*	0.827	1.000	0.038*	0.616
Seed		<0.001*	1.000	0.033*	1.000	<0.001*	0.080	0.007*	0.038*	<0.001*	1.000	0.006*	0.433
Aggregation		1.000	0.114	0.012*	1.000	<0.001*	0.014*	0.046*	<0.001*	1.000	0.004*	1.000	0.038*
Compound		0.006*	0.001*	0.005*	0.044*	0.002*	0.002*	0.043*	<0.001*	0.011*	0.004*	<0.001*	0.007*
Breast Tissue		<0.001*	0.038*	0.042*	<0.001*	<0.001*	<0.001*	<0.001*	0.002*	<0.001*	<0.001*	0.034*	<0.001*
Pima		0.010*	1.000	0.008*	0.458	<0.001*	1.000	1.000	1.000	<0.001*	1.000	1.000	0.919
Room Occupancy		<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*
Rice		<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*
Wifi		<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	<0.001*	0.245	0.326	<0.001*	<0.001*	<0.001*	<0.001*
SUM	*	11	9	10	9	9	10	8	11	12	10	9	10
	–	3	5	4	5	2	4	6	3	2	4	5	4

Bảng 11 Kết quả thử nghiệm độ chính xác giai đoạn hai.

Dataset	Average Accuracy (Rank)						
	A1	A2	A3	A4	A5	A6	A7
Iris	0.908 (3)	0.914 (2)	0.899(6)	0.901 (5)	0.89 (7)	0.960 (1)	0.902 (4)
Flame	0.855 (2)	0.848 (4)	0.843 (6)	0.857 (1)	0.847 (5)	0.850 (3)	0.836 (7)
Jain	0.879 (5)	0.882 (1)	0.881 (2)	0.881 (2)	0.881 (2)	0.846 (7)	0.874 (6)
Wine	0.952 (5)	0.955 (4)	0.951 (6)	0.950 (7)	0.958 (3)	0.970 (1)	0.961 (2)
Glass	0.066 (7)	0.581 (2)	0.561 (4)	0.570 (3)	0.551 (5)	0.626 (1)	0.548 (6)
Ecoli	0.817 (4)	0.777 (6)	0.792 (5)	0.831 (2)	0.832 (1)	0.765 (7)	0.824 (3)
Seed	0.899 (3)	0.900 (2)	0.890 (6)	0.891 (4)	0.891 (4)	0.914 (1)	0.887 (7)
Aggregation	0.909 (2)	0.910 (1)	0.903 (4)	0.908 (3)	0.896 (6)	0.889 (7)	0.901 (5)
Compound	0.838 (5)	0.845 (3)	0.844 (4)	0.847 (2)	0.852 (1)	0.821 (7)	0.828 (6)
Breast Tissue	0.611 (2)	0.615 (1)	0.574 (5)	0.603 (3)	0.565 (7)	0.579 (4)	0.572 (6)
Pima	0.681 (2)	0.708 (1)	0.662 (6)	0.666 (5)	0.672 (4)	0.673 (3)	0.654 (7)
Room Occupancy	0.862 (6)	0.889 (1)	0.868 (4)	0.871 (3)	0.884 (2)	0.866 (5)	0.854 (7)
Rice	0.912 (6)	0.943 (2)	0.917 (5)	0.945 (1)	0.928 (3)	0.924 (4)	0.903 (7)
Wifi	0.945 (7)	0.962 (1)	0.952 (3)	0.952 (3)	0.947 (6)	0.960 (2)	0.951 (5)
Sum of Rank	**59**	**31**	**66**	**44**	**56**	**53**	**78**

Bảng 12 Kết quả thử nghiệm ARI giai đoạn hai.

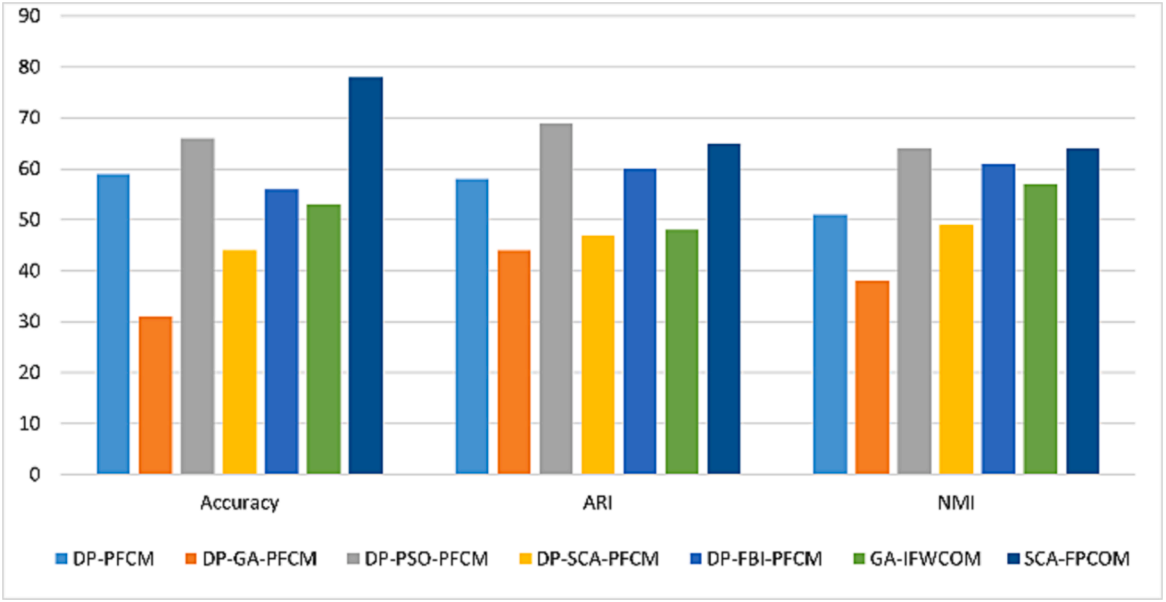
Dataset	Average ARI (Rank)						
	A1	A2	A3	A4	A5	A6	A7
Iris	0.759 (3)	0.774 (2)	0.740 (6)	0.744 (4)	0.723 (7)	0.89 (1)	0.742 (5)
Flame	0.501 (3)	0.482 (5)	0.469 (7)	0.507 (2)	0.481 (6)	0.68 (1)	0.487 (4)
Jain	0.569 (5)	0.575 (1)	0.574 (2)	0.572 (4)	0.573 (3)	0.543 (7)	0.566 (6)
Wine	0.858 (4)	0.865 (3)	0.857 (5)	0.852 (6)	0.877 (2)	0.852 (6)	0.889 (1)
Glass	0.194 (2)	0.183 (5)	0.172 (6)	0.190 (3)	0.161 (7)	0.532 (1)	0.184 (4)
Ecoli	0.419 (4)	0.352 (7)	0.359 (6)	0.435 (1)	0.430 (2)	0.367 (5)	0.428 (3)
Seed	0.729 (3)	0.730 (2)	0.704 (6)	0.707 (4)	0.706 (5)	0.826 (1)	0.692 (7)
Aggregation	0.683 (7)	0.695 (5)	0.701 (2)	0.700 (3)	0.723 (1)	0.698 (4)	0.694 (6)
Compound	0.547 (5)	0.555 (3)	0.554 (4)	0.557 (2)	0.562 (1)	0.532 (6)	0.500 (7)
Breast Tissue	0.393 (2)	0.370 (4)	0.383 (3)	0.320 (5)	0.292 (7)	0.482 (1)	0.308 (6)
Pima	0.115 (4)	0.166 (3)	0.010 (7)	0.102 (6)	0.106 (5)	0.355 (1)	0.233 (2)
Room Occupancy	0.739 (6)	0.816 (1)	0.793 (3)	0.79 (4)	0.802 (2)	0.764 (5)	0.721 (7)
Rice	0.853 (3)	0.856 (2)	0.832 (7)	0.857 (1)	0.844 (6)	0.848 (5)	0.850 (4)
Wifi	0.861 (7)	0.895 (1)	0.870 (5)	0.880 (2)	0.869 (6)	0.873 (4)	0.878 (3)
Sum of Rank	**58**	**44**	**69**	**47**	**60**	**48**	**65**

Bảng 13 Kết quả thực nghiệm NMI giai đoạn hai.

Dataset	Average NMI (Rank)						
	A1	A2	A3	A4	A5	A6	A7
Iris	0.764 (2)	0.775 (1)	0.747 (5)	0.748 (4)	0.744 (7)	0.752 (3)	0.746 (6)
Flame	0.455 (2)	0.439 (3)	0.43 (5)	0.463 (1)	0.438 (4)	0.392 (7)	0.418 (6)
Jain	0.533 (3)	0.533 (3)	0.526 (6)	0.529 (5)	0.536 (1)	0.526 (6)	0.536 (1)
Wine	0.842 (5)	0.848 (4)	0.842 (5)	0.836 (7)	0.859 (3)	0.863 (2)	0.892 (1)
Glass	0.353 (4)	0.346 (5)	0.33 (7)	0.357 (3)	0.331 (6)	0.641 (1)	0.384 (2)
Ecoli	0.596 (3)	0.556 (5)	0.569 (4)	0.618 (2)	0.62 (1)	0.481 (7)	0.532 (6)
Seed	0.701 (2)	0.696 (3)	0.674 (7)	0.676 (5)	0.675 (6)	0.785 (1)	0.678 (4)
Aggregation	0.836 (3)	0.837 (1)	0.836 (3)	0.837 (1)	0.833 (6)	0.798 (7)	0.834 (5)
Compound	0.708 (6)	0.714 (2)	0.713 (4)	0.714 (2)	0.717 (1)	0.712 (5)	0.695 (7)
Breast Tissue	0.562 (2)	0.536 (5)	0.539 (3)	0.537 (4)	0.521 (6)	0.5982 (1)	0.508 (7)
Pima	0.07 (4)	0.105 (3)	0.057 (6)	0.055 (7)	0.058 (5)	0.246 (1)	0.182 (2)
Room Occupancy	0.843 (5)	0.875 (1)	0.853 (3)	0.847 (4)	0.839 (6)	0.864 (2)	0.833 (7)
Rice	0.876 (6)	0.903 (1)	0.886 (3)	0.897 (2)	0.882 (4)	0.852 (7)	0.881 (5)
Wifi	0.9 (4)	0.945 (1)	0.905 (3)	0.931 (2)	0.899 (5)	0.886 (7)	0.899 (5)
Sum of Rank	**51**	**38**	**64**	**49**	**61**	**57**	**64**

quy trình được áp dụng như ở giai đoạn đầu bằng cách tính tổng các giá trị xếp hạng của từng thuật toán.

Như có thể thấy trong Bảng 11, Bảng 12 và Bảng 13, tổng các giá trị xếp hạng của thuật toán DP-GA-PFCM là giá trị nhỏ nhất so với các thuật toán khác nhất quán về độ chính xác, ARI và NMI. Mặc dù đối với mỗi tập dữ liệu, thuật toán xếp hạng đầu tiên khác nhau ở từng thước đo hiệu suất, nhưng thuật toán DP-GA-PFCM luôn hoạt động tốt hơn các thuật toán khác dựa trên độ chính xác, ARI và NMI. Nó có thể



Hình. 4. Tổng xếp hạng ở giai đoạn thứ hai của thử nghiệm.

kết luận rằng DP-GA-PFCM có thể mang lại kết quả tốt hơn. Tương tự như vậy trong giai đoạn đầu tiên của thử nghiệm, tổng thứ hạng của tất cả các thuật toán đã thử nghiệm cũng được trình bày trong Hình 4 để trực quan hóa tốt hơn. Có thể thấy rằng DP-GA-PFCM được đề xuất xếp hạng số 1 cho ba chỉ số xác thực, tức là độ chính xác, ARI và NMI xét về tổng thứ hạng cho tất cả các tập dữ liệu được thử nghiệm. DP-SCA-PFCM xếp ở vị trí thứ 2 trong khi vị trí thứ 3 là thuật toán GA-IFWCOM.

Thử nghiệm thống kê giai đoạn hai được thực hiện để xác định xem có sự khác biệt hay không dựa trên các thuật toán được sử dụng là thuật toán DP-PFCM, thuật toán DP-GA-PFCM, thuật toán DP-PSO-PFCM, thuật toán DP-SCA-PFCM và thuật toán DP-FBI-PFCM. Tương tự như kết quả ở giai đoạn đầu, có ít nhất một thuật toán khác dựa trên thuật toán được sử dụng. Một bài kiểm tra hậu kiểm được tiến hành để xác định thuật toán nào có sự khác biệt. Bảng 14 cho thấy kết quả kiểm tra Dunn-Bonferroni cho từng cặp nhóm về độ chính xác, ARI và NMI. Kết quả cho thấy DP-GA-PFCM tốt hơn đáng kể so với các thuật toán khác.

4.4. Phân tích và thảo luận

Tám trong số mười bốn bộ dữ liệu chứa các giá trị ngoại lệ, bao gồm Ngọn lửa, Rượu, Thủy tinh, Ecoli, Hợp chất, Hạt giống, Mô vú và Pima. Như được hiển thị trong Bảng 6, Bảng 7 và Bảng 8, thuật toán PFCM có thể khắc phục sự hiện diện của các ngoại lệ bằng cách tối ưu hóa độ chính xác, ARI và hiệu suất NMI của thuật toán PFCM và Dp-PFCM trên các bộ dữ liệu Iris, Flame, Wine, Glass, Seed, Hợp chất, Mô vú và Pima. Hơn nữa, tổng các giá trị xếp hạng cho thấy việc sử dụng thuật toán PFCM có độ chính xác, ARI và NMI hoạt động tốt nhất. Mặc dù tập dữ liệu Iris không chứa các ngoại lệ nhưng thuật toán đỉnh mật độ mang lại kết quả tốt hơn. Ngoài ra, bộ dữ liệu Jain và Aggregation không chứa bất kỳ ngoại lệ nào, do đó PFCM không thể mang lại kết quả tốt hơn. Mặc dù Ecoli có các ngoại lệ nhưng hiệu suất của nó dường như không đạt yêu cầu do có ba lớp có ít hơn hoặc bằng năm thành viên. Điều kiện này gây khó khăn cho cả thuật toán mật độ đỉnh và PFCM để cho kết quả tốt hơn.

Nhìn chung, thuật toán DP-GA-PFCM có sự khác biệt đáng kể nhất so với các thuật toán khác dựa trên độ chính xác, ARI và NMI. Do thuật toán DP-GA-PFCM có thứ hạng thấp nhất trong số các thuật toán khác nên thuật toán DP-GA-PFCM vượt trội hơn các thuật toán khác. Bằng cách sử dụng thuật toán di truyền, thuật toán DP-GA PFCM có thể được tối ưu hóa cho các tham số và trung tâm cụm, mang lại kết quả tốt hơn. Có thể thấy, các thuật toán GA, PSO, SCA, FBI thực chất là siêu hình học dựa trên dân số. Mặc dù các siêu dữ liệu đó có thể xử lý cả các vấn đề rời rạc và liên tục, GA hiệu quả hơn trong việc xử lý các vấn đề rời rạc, trong khi các thuật toán PSO, SCA và FBI xử lý các vấn đề liên tục tốt hơn [22–24]. Từ kết quả tổng thể, dựa trên GA cho kết quả tốt hơn so với các phương pháp siêu dữ liệu khác. Ví dụ: DP-PFCM dựa trên GA tốt hơn so với DP-PFCM dựa trên PSO, DP-PFCM dựa trên SCA, DP-PFCM dựa trên FBI hoặc GA-IFWCOM cũng tốt hơn SCA-FPCOM. Ở đây, các thao tác di truyền đóng vai trò quan trọng trong việc thăm dò và khai thác tốt trong không gian tìm kiếm. Hơn nữa, các thuật toán PSO, SCA và FBI có xu hướng khó tìm ra giải pháp tối ưu vì MinMax Scaler thay đổi tâm cụm trong phạm vi từ 0 đến 1 khiến phương pháp cập nhật riêng lẻ trên các thuật toán này kém hiệu quả hơn vì giá trị cập nhật không thể nhỏ hơn 0 hoặc>1. Vì nghiên cứu này giải quyết các vấn đề liên tục nên các thuật toán PSO, SCA và FBI có lợi thế hơn nhưng các hoạt động di truyền hiệu quả và hiệu quả hơn để mang lại kết quả tối ưu. Kết quả được chứng minh thông qua kiểm tra thống kê trong Bảng 14, trong đó DP-GA-PFCM hoạt động tốt hơn đáng kể trong hầu hết các bộ dữ liệu được kiểm tra. Hơn nữa, Bảng 15 cho thấy độ lệch chuẩn của từng thuật toán sau 30 lần chạy về độ chính xác, ARI và NMI. Kết quả chứng minh rằng DP-GA-PFCM được đề xuất mang lại kết quả đáng tin cậy và chắc chắn hơn với độ lệch chuẩn thấp nhất.

Ngoài ra, thời gian tính toán là thời gian cần thiết để thực hiện thuật toán được sử dụng cũng được phân tích. Bảng 16 thể hiện kết quả thời gian tính toán (tính bằng giây) của từng thuật toán trên mỗi tập dữ liệu.

TXemacbolned1-s4so sánh theo cặp.

Pair		Accuracy						ARI						NMI					
		A2 vs. A1	A2 vs. A3	A2 vs. A4	A2 vs. A5	A2 vs. A6	A2 vs. A7	A2 vs. A1	A2 vs. A3	A2 vs. A4	A2 vs. A5	A2 vs. A6	A2 vs. A7	A2 vs. A1	A2 vs. A3	A2 vs. A4	A2 vs. A5	A2 vs. A6	A2 vs. A7
Dataset																			
Iris		0.07	0.00*	0.00*	0.00*	0.00*	0.00*	0.8	0.00*	0.00*	0.00*	0.00*	0.00*	0.26	0.00*	0.00*	0.00*	0.00*	0.00*
Flame		0.04*	0.03*	0.00*	1.00	0.00*	0.00*	0.04*	0.03*	0.00*	1.000	0.00*	0.00*	0.03*	0.03*	0.00*	1.00	0.00*	0.00*
Jain		0.01*	1.00	1.00	1.00	0.00*	0.00*	0.01*	1.00	1.00	1.00	0.00*	0.00*	1.00	0.01*	0.56	1.00	0.00*	0.00*
Wine		0.69	0.21	0.02*	0.16	0.00*	0.00*	1.00	1.00	0.01*	0.02*	0.14	0.00*	1.00	1.00	0.01*	0.01*	0.00*	0.00*
Glass		0.00*	0.00*	0.02*	0.00*	0.00*	0.00*	0.04*	0.17	1.00	0.00*	0.00*	0.00*	1.00	0.01*	1.00	0.02*	0.00*	0.00*
Ecoli		0.00*	0.72	0.00*	0.00*	0.00*	0.00*	0.00*	1.00	0.00*	0.00*	0.00*	0.00*	0.00*	0.85	0.00*	0.00*	0.00*	0.00*
Seed		1.00	0.00*	0.00*	0.00*	0.00*	0.00*	1.00	0.00*	0.00*	0.00*	0.00*	0.00*	1.00	0.00*	0.00*	0.00*	0.00*	0.01*
Aggregation		1.00	0.03*	1.00	0.00*	0.00*	0.00*	0.01*	1.00	1.00	0.00*	0.48	0.00*	1.00	1.00	1.00	0.00*	0.00*	0.00*
Compound		0.03*	1.00	1.00	0.18	0.00*	0.00*	0.01*	1.00	1.00	0.47	0.00*	0.00*	0.04*	1.00	1.00	1.00	0.00*	0.00*
Breast Tissue		1.00	0.00*	0.01*	0.00*	0.00*	0.00*	0.00*	0.516	0.01*	0.00*	0.00*	0.00*	0.00*	1.00	1.00	0.01*	0.00*	0.00*
Pima		0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*
Room Occupancy		0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.02*	0.00*
Rice		0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.32	0.00*	0.13	0.00*	0.00*	0.00*	0.00*	0.00*	0.25	0.00*	0.00*	0.00*
Wifi		0.00*	0.00*	0.00*	0.00*	0.16	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*	0.00*
SUM	*	9	10	11	10	13	14	10	7	9	11	12	14	8	9	8	11	14	14
	–	5	4	3	4	1	0	4	7	5	3	2	0	6	5	6	3	0	0

Bảng 15 Độ lệch chuẩn của từng thuật toán.

Algorithm	Accuracy	ARI	NMI
K-Means	0.029	0.021	0.133
FCM	0.025	0.018	0.102
PFCM	0.020	0.016	0.081
DP-FCM	0.016	0.014	0.062
DP-PFCM	0.016	0.017	0.073
DP-GA-PFCM	0.012	0.010	0.059
DP-PSO-PFCM	0.016	0.014	0.087
DP-SCA-PFCM	0.021	0.018	0.075
GA-IFWCOM	0.028	0.032	0.068
SCA-FPCOM	0.015	0.026	0.064

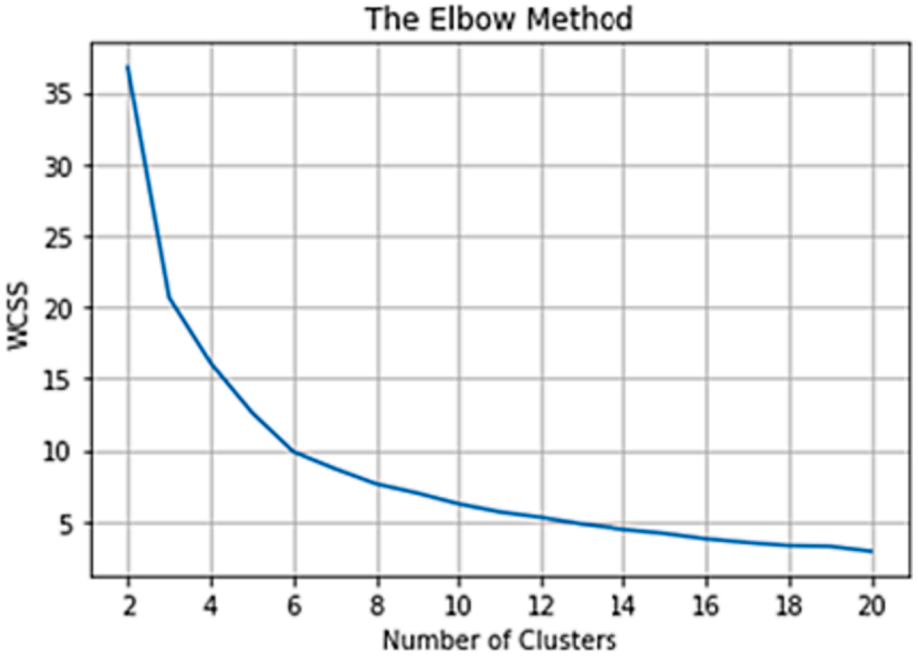
Dựa trên kết quả, việc thêm phương pháp DPC sẽ mất thời gian tính toán lâu hơn một chút so với các phương pháp thông thường như thuật toán *K*-means, thuật toán FCM và thuật toán PFCM. Tuy nhiên, kết quả ở giai đoạn thử nghiệm đầu tiên đã chứng minh rằng DP-PFCM tốt hơn đáng kể so với các phương pháp truyền thống khác mà không cần thêm *meta*-heuristic. Hơn nữa, việc kết hợp siêu dữ liệu với phân cụm sẽ mất nhiều thời gian hơn các phương pháp truyền thống khác vì siêu dữ liệu thực hiện lặp đi lặp lại để tìm giải pháp tối ưu cho thuật toán PFCM. các thời gian tính toán của DP-GA-PFCM cũng tốt hơn so với GA-IFWCOM và SCA-FPCOM. Ngoài ra, thuật toán FBI là thuật toán có thời gian tính toán dài nhất do tính phức tạp của thủ tục cập nhật các cá thể trong quần thể của nó. Mặc dù thời gian dành cho GA, PSO và SCA không khác nhau nhiều nhưng GA có thể mang lại kết quả tốt hơn, như đã trình bày trong giai đoạn thứ hai của thử nghiệm. Kết quả là GA hiệu quả hơn các thuật toán PSO, SCA và FBI.

5. Nghiên cứu trường hợp

Trong nghiên cứu điển hình này, tập dữ liệu phân khúc khách hàng từ Mendeley Data đã được triển khai. Bộ dữ liệu kinh doanh bán lẻ này bao gồm 1288 bản ghi khách hàng với năm biến bao gồm ID khách hàng, ngày mua hàng gần đây nhất, lần mua gần đây, tần suất và tiền tệ. Đối với phân tích cụm, ba biến số cuối cùng, lần truy cập gần đây, tần suất và tiền tệ (RFM) có vai trò quan trọng trong phân khúc khách hàng. Phân tích RFM là một cách để xác định hành vi của khách hàng. Lần gần đây đề cập đến thời gian kể từ giao dịch cuối cùng của khách hàng. Thời gian gần đây càng nhỏ thì khách hàng thực hiện giao dịch gần đây càng nhiều. Tần suất khách hàng đề cập đến số lượng giao dịch mà khách hàng thực hiện trong một khoảng thời gian nhất định. Tần suất càng lớn thì số lượng giao dịch được thực hiện bởi

Bảng 16 Thời gian tính toán (giây).

	K-means	FCM	PFCM	DP-FCM	DP-PFCM	DP-GA-PFCM	DP-PSO-PFCM	DP-SCA-PFCM	DP-FBI-PFCM	GA-IFWCOM	SCA-FPCOM
Iris	0.02	1.64	0.55	2.13	2.02	48.4	51.4	48.6	198.5	221.4	178.2
Flame	0.01	1.58	0.69	2.45	3.07	77.0	65.4	62.1	234.1	266.8	243.1
Jain	0.01	2.41	1.14	4.29	6.08	117.9	107.1	99.2	391.2	357.3	386.5
Wine	0.01	2.49	0.86	3.04	2.71	76.5	83.3	73.5	369.2	482.5	563.7
Glass	0.04	7.05	1.75	8.48	5.56	157.2	169.1	148.1	962.3	1823.4	1783.4
Ecoli	0.05	10.5	2.93	14.5	12.0	251.7	277.4	238.2	1052.8	2290.1	3201.6
Seed	0.02	2.47	0.87	3.28	3.17	78.1	81.7	73.4	249.2	362.3	328.4
Aggregation	0.04	23.7	6.40	30.6	47.9	577.3	672.3	558.8	2220.6	2531.6	2302.9
Compound	0.03	9.99	2.49	11.5	12.9	215.5	187.9	214.2	1281.6	986.7	862.2
Breast Tissue	0.04	2.64	0.80	3.42	2.01	72.4	77.5	63.6	266.7	899.3	783.1
Pima	0.23	7.13	2.99	15.5	18.5	256.7	260.1	231.7	951.8	1024.9	1102.3
Room Occupancy	3.24	18.64	18.22	30.2	33.57	451.2	464.1	398.0	1104.2	1124.2	938.6
Rice	1.48	14.79	12.05	16.41	20.14	326.3	347.5	302.6	780.5	823.5	643.5
Wifi	1.12	12.90	9.87	13.69	14.08	298.6	320.9	285.7	737.1	798.3	624.9



Hình. 5. Đầu ra của phương thức khuỷu tay.

Bảng 17 Phân loại RFM.

Variables	Small	Medium	High
Recency	< 251	251–320	> 320
Frequency	< 2	2–15	> 15
Monetary	< 16	16–45	> 45

khách hàng. Số tiền của khách hàng là số tiền họ phát hành trong một khoảng thời gian nhất định. Số tiền càng lớn thì khách hàng sẽ chi tiêu càng nhiều. Phân tích RFM đã được sử dụng rộng rãi trong các ứng dụng như bán lẻ để xác định chiến lược tiếp thị và đã được chứng minh là một kỹ thuật mạnh mẽ để xếp hạng khách hàng dựa trên lịch sử giao dịch trước đó.

5.1. Kết quả phân cụm

Do nghiên cứu này đề xuất một thuật toán để xử lý dữ liệu nhiễu và dữ liệu ngoại lệ nên quá trình tiền xử lý dữ liệu nhằm loại bỏ dữ liệu chứa các giá trị bị thiếu và loại bỏ các giá trị âm. Do đó, tổng số dữ liệu được sử dụng là 1281 bản ghi. Các biến được sử dụng để phân tích cụm là lần truy cập gần đây, tần suất và tiền tệ. Hơn nữa, do đơn vị của các biến là khác nhau nên Min-Max Scaler được sử dụng để biến đổi giá trị của từng biến trong khoảng từ 0 đến 1. Thuật toán đề xuất yêu cầu hai tham số đầu vào là số cụm và số lần lặp tối đa. Số lượng cụm được xác định bằng phương pháp Elbow như trong Hình 5. Từ biểu đồ, số cụm được sử dụng là 6 cụm. Ngoài ra, số lần lặp tối đa được sử dụng là 100.

5.2. Phân tích và thảo luận

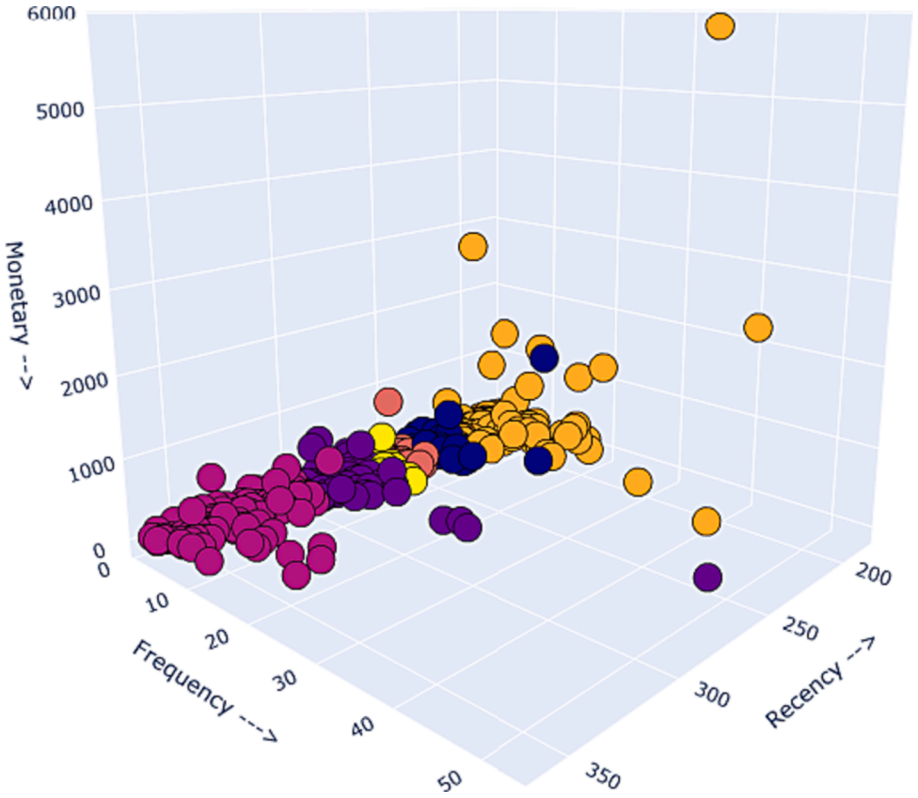
Phân khúc thị trường trong ngành thường được thảo luận trong nhiều nghiên cứu sử dụng nhiều cách tiếp cận khác nhau, bao gồm cả phân cụm. Rahim và cộng sự. [29] giải thích rằng bằng cách sử dụng máy học, độ chính xác cao đã đạt được theo tư cách thành viên của khách hàng. Mô hình RFM được áp dụng cho xác định hành vi của khách hàng trong ngành bán lẻ. Tuy nhiên, trong ngành du lịch, machine learning cũng có thể phân loại khách hàng dựa trên đánh giá để đưa ra quyết định liên quan đến chính sách xanh và thực hành thân thiện với môi trường.

Thời gian tính toán cần thiết trong tập dữ liệu nghiên cứu điển hình sử dụng thuật toán DP-GA-PFCM là 1017,32 giây. Vì GA vượt trội hơn so với các siêu dữ liệu khác, nên có thể nói rằng cách GA cập nhật cá nhân của nó bằng chéo và đột biến sẽ hiệu quả và hiệu quả hơn trong việc thu được sự kết hợp giữa tham số và trung tâm cụm so với PSO bằng cách sử dụng vận tốc, SCA với các phương trình sin và cos và thuật toán FBI với “điều tra” và “theo đuổi” để có được cá nhân mục tiêu. Việc chuyển đổi trong phép tính GA có thể dự đoán việc mắc phải tối ưu cục bộ và tạo ra sự khác biệt để mở rộng phạm vi tìm kiếm của nó [30]. Để dễ dàng xác định các loại khách hàng cho từng cụm, các biến được sử dụng được chia thành ba loại: nhỏ, trung bình và cao như trong Bảng 17.

Biểu đồ của từng thành viên khách hàng trong mỗi cụm được hiển thị trong Hình 6. Có sáu cụm với màu sắc và đặc điểm khác nhau. Đặc điểm chi tiết của từng cụm được minh họa trong Bảng 18. Trong kinh doanh bán lẻ, khách hàng tốt được biểu thị bằng mức độ gần đây nhỏ, tần suất cao và tiền tệ cao để thu được nhiều lợi nhuận hơn. Dựa trên kết quả, những khách hàng tiềm năng nhất được đại diện bởi Nhóm 1 và Nhóm 5. Họ có tần suất truy cập gần đây nhỏ và trung bình và chỉ khác nhau về số tiền chi tiêu. Nó có nghĩa là gần đây họ đã thực hiện giao dịch với

Bảng 18 Đặc điểm của từng cụm.

Cluster	Recency	Frequency	Monetary	Members
Cluster 1	Small	Medium	High	196
Cluster 2	High	Medium	Medium	341
Cluster 3	Medium	Medium	Small	194
Cluster 4	Medium	Medium	Medium	108
Cluster 5	Small	Medium	Medium	334
Cluster 6	Medium	Medium	Medium	108



Hình. 6. Kết quả phân cụm.

several transactions between 2 and 15 times. Cluster 1 can be said to be the best customer because the expenses are greater than Cluster 5. These clusters need to be appreciated by giving rewards to them for being the customers who have contributed the most to the company. Cluster 2 is an occasional customer which is indicated by the high recency and medium frequency. Accordingly, they only occasionally come to buy some stuff. Thus, the company can provide special offers such as discounts to increase their visits. Saving customers are represented in cluster 3. They only spent a small amount of money which means only buying things that are not too expensive such as daily or monthly needs. Offering a membership and product recommendation can lead to upselling the product. Cluster 4 and Cluster 6 are identical. They have medium recency, medium frequency, and medium monetary. It can be said that they are "need attention" customers. They are in an intermediate condition, the right strategy can be to loyal customers. Otherwise, the bad strategy will lead to a loss of customers. Even though they are the same, after being seen in more detail, Cluster 4 has a customer segment that will be more inclined to be loyal customers. Some of them have lower recency than cluster 6. So, companies need to provide strategies such as promotions to retain customers in Cluster 4 and attract customers in Cluster 6. Cluster 5 is a stable customer or can be raised to potential loyalists, they are recent customers with average frequency and spent a good amount of money. With a willingness to pay, consider premium offers and offer luxury products.

In summary, the results indicate that each segment should be implemented a different marketing strategy. The right and specific strategy can influence the customer behavior of each cluster. In the end, the company will get the maximum profit.

6. Conclusion

This study proposed an algorithm that combines density peak clustering with possibilistic fuzzy c-means algorithm and GA. The proposed DP-GA-PFCM algorithm can overcome (1) the presence of noise and outlier data and (2) the sensitivity of initial cluster centers. These computational results have proved that the density peak can produce initial cluster centers more efficiently instead of using random numbers. In addition, using a possibilistic concept can handle the influence of noise and outlier data. The DP-PFCM algorithm which integrates with metaheuristics, such as GA, PSO, SCA, and FBI algorithms, to find the optimal combination of parameters and cluster centers can yield better performance. In addition, the result shows that GA can enhance the clustering performance more than the others. According to the result of the DP-GA-PFCM algorithm for the case study, there are six customer clusters with their respective characteristics. Also, this study provides some strategies to maintain and attract customers.

Though the experimental results of the proposed algorithm have shown that it gives better performance, it still can be improved in some ways. The DP-GA-PFCM algorithm requires the number of clusters as an input, it is better if the algorithm can automatically determine the number of clusters itself. Although GA can provide better results, future research could implement other metaheuristics or modify the existing metaheuristics to reduce the computational time and increase the performance. Besides, the study can be extended to validate the results of high-dimensional datasets. Moreover, the actual loss with statistical significance can be analyzed to evaluate the clustering performance in future research.

Declaration of Competing Interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgments

This research is funded by Funds for Science and Technology Development of the University of Danang under project number B2020-DN02-83. This support is much appreciated.

References

[1] A. Ahani, M. Nilashi, O. Ibrahim, L. Sanzogni, S. Weaven, Market segmentation and travel choice prediction in Spa hotels through TripAdvisor's online reviews, Int. J. Hosp. Manag. 80 (2019) 52–77.
[2] J. Zhou, L. Zhai, A. Pantelous, Market segmentation using high-dimensional sparse consumers data, Expert Syst. Appl. 145 (2020) 1–17.
[3] H. Zhou, R. Norman, K. Kelobonye, J. Xia, B. Hughes, G. Nikolova, T. Falkmer, Market segmentation approach to investigate existing and potential aviation markets, Transp. Policy 99 (2020) 120–135.
[4] D. Moussa, N. Eissa, H. Abounaser, A. Badr, Design of novel metaheuristic techniques for clustering, IEEE Access 6 (2018) 77350–77358.
[5] M. Rezaei, Improving a centroid-based clustering by using suitable centroids from another clustering, J. Classif. 37 (2) (2020) 352–365.
[6] Y. Wang, D. Wang, Y. Zhou, X. Zhang, C. Quek, VDPC: Variational density peak clustering algorithm, Inf. Sci. 621 (2023) 627–651.
[7] Y. Li, L. Sun, Y. Tang, DPC-FSC: An approach of fuzzy semantic cells to density peaks clustering, Inf. Sci. 616 (2022) 88–107.
[8] X.-y. Liu, J.-C. Fan, Z.-W. Chen, Improved fuzzy c-means algorithm based on density peak, Int. J. Mach. Learn. Cybern. 11 (3) (2020) 545–552.
[9] W. Tong, S. Liu, X.Z. Gao, A density-peak-based clustering algorithm of automatically determining the number of clusters, Neurocomputing (2020) 1–12.
[10] N. Pal, K. Pal, J. Keller, J. Bezdek, A possibilistic fuzzy c-means clustering algorithm, IEEE Trans. Fuzzy Syst. 13 (4) (2005) 517–530.
[11] R. Krishnapuram, J.M. Keller, A possibilistic approach to clustering, IEEE Trans. Fuzzy Syst. 1 (2) (1993) 98–110.
[12] D. Zeebaree, H. Haron, A. Abdulazeez, S. Zeebaree, Combination of K-means clustering with genetic algorithm: A review, Int. J. Appl. Eng. Res. 12 (24) (2017) 14238–14245.
[13] L. Zhu, Safety detection algorithm in sensor network based on ant colony optimization with improved multiple clustering algorithms, Saf. Sci. 118 (2019) 96–102.
[14] R.J. Kuo, J.-Y. Lin, T.P.Q. Nguyen, An application of sine cosine algorithm-based fuzzy possibilistic c-ordered means algorithm to cluster analysis, Soft Comput. 25 (5) (2021) 3469–3484.
[15] A. Chehouri, R. Younes, J. Khoder, J. Perron, A. Ilinca, A selection process for genetic algorithm using clustering analysis, Algorithms 10 (123) (2017) 1–15.
[16] A. Golmohammadi, H. Bani-Asadi, H. Zanjani, H. Tikani, A genetic algorithm for preemptive scheduling of a single machine, Int. J. Ind. Eng. Comput. 7 (2016) 607–614.
[17] M. Du, S. Ding, X. Xu, Y.u. Xue, Density peaks clustering using geodesic distances, Int. J. Mach. Learn. Cybern. 9 (8) (2018) 1335–1349.
[18] X. Chen, D. Li, H. Li, An improved type-2 possibilistic fuzzy c-means clustering algorithm with application for MR image segmentation, International Journal of Signal Processing, Imgae Processing and Pattern Recognition 9 (11) (2016) 363–370.
[19] A. Hassanat, K. Almohammadi, E. Alkafaween, E. Abunawas, A. Hammouri, V.B. S. Prasath, Choosing Mutation and Crossover Ratios for Genetic Algorithms—A Review with a New Dynamic Approach, Information. 10 (12) (2019) 390.
[20] L. Haldurai, T. Madhubala, R. Rajalakshmi, A study on genetic algorithm and its applications, Int. J. Comput. Sci. Eng. 4 (10) (2016) 139–143.
[21] E. Michielssen, S. Ranjithan, R. Mittra, Optimal multilayer filter design using real coded genetic algorithms, IEE Proceedings J-Optoelectronics 139 (6) (1992) 413.
[22] Y. Xue, B. Xue, M. Zhang, Self-adaptive particle swarm optimization for large-scale feature selection in classification, ACM Trans. Knowl. Discov. Data (TKDD) 13 (5) (2019) 1–27.
[23] M.A. Tawhid, P. Savsani, Discrete sine cosine algorithm (DSCA) with local search for solving traveling salesman problem, Arab. J. Sci. Eng. 44 (4) (2019) 3669–3679.
[24] J. Chou, N. Nguyen, FBI inspired meta-optimization, Appl. Soft Comput. 93 (2020) 1–28.
[25] R.J. Kuo, P. Amornnikun, T.P.Q. Nguyen, Metaheuristic-based possibilistic multivariate fuzzy weighted c-means algorithms for market segmentation, Appl. Soft Comput. 96 (2020) 1–14.
[26] R.J. Kuo, Y.R. Zheng, T.P.Q. Nguyen, Metaheuristic-based possibilistic fuzzy k-modes algorithms for categorical data clustering, Inf. Sci 557 (2021) 1–15.
[27] X.F. Song, Y. Zhang, Y.N. Guo, X.Y. Sun, Y.L. Wang, Variable-size cooperative coevolutionary particle swarm optimization for feature selection on high-dimensional data, IEEE Trans. Evol. Comput. 24 (5) (2020) 882–895.
[28] R.J. Kuo, C.K. Chang, T.P.Q. Nguyen, T.W. Liao, Application of genetic algorithm-based intuitionistic fuzzy weighted c-ordered-means algorithm to cluster analysis, Knowl. Inf. Syst 63 (7) (2021) 1935–1959.
[29] M.A. Rahim, M. Mushafiq, S. Khan, Z.A. Arain, RFM-based repurchase behavior for customer segmentation, J. Retail. Consum. Serv. 61 (2021) 1–9.
[30] R.J. Kuo, T.C. Lin, F.E. Zulvia, C.Y. Tsai, A hybrid metaheuristic and kernel intuitionistic fuzzy c-means algorithm for cluster analysis, Appl. Soft Comput. 67 (2018) 299–308.